从 Direct 基线到可核查的定位反例

主线转向 query 驱动的时间定位

Direct 诊断 → Grounding 测试 → 反例核查

林逸飞　2026.10.28–10.30

承接 10 月 27 日组会；实验结果截至 10 月 29 日

52

条扩样指标反例

22 条较明确定位错误

原始帧助手初筛，待人工复核

依据：组会后工作总结与归档实验报告

已完成基线与诊断， Agent 修复尚待验证

10.28–10.29 已完成

整表评分

定位同分退化
检验时间键

单目标诊断

固定两处目标
检验输出粒度

直接定位

QV20 + 新 100
保留完整分母

反例核查

52 条逐例审核
分开四类问题

下一步：先验证具体定位错误能否被局部补证修复

本阶段尚无记忆、比较器或回看的新增修复收益；此前基线不重复计入。

依据：组会后工作总结（10.30）

整表输出把视频内所有片段打成同分

25/25

有效响应均在视频内同分

QV20 + TVSum5

64 帧 + 真实时间戳 + query

Qwen3-VL-8B-Instruct

[80, 80, 80, 80, …]

常数形式示例；每个 2s 片段输出 0–100 分

原始响应即为常数，不是解析器广播造成。

QV20： mAP 10.71 / Hit@1 15.00；这不能证明模型完全没有时间理解。

TVSum 第 6 条 OOM， Direct 仅完成 5/10；未补跑。

依据： Direct pilot 报告（10.28）

时间键无效；单目标判断出现部分分差

输出条件	调用规模	观察结果
原始评分整表	20 次	20/20 视频内同分
显式时间键	20 次	仍 20/20 同分， mAP / Hit@1 不变
单目标 2s 判断	40 次	20 对固定目标： 11 对异值， 9 对同分

11/20 是分差比例，不是准确率

共享 QV20 、原 64 帧与模型；单目标只覆盖 40 个时间格，未计算新全网格精度。
目标范围、输出长度和注意力聚焦共同变化，不能当作纯时间理解因果实验。

依据：时间键报告（ 10.28 ）、单目标粒度报告（ 10.29 ）

直接输出时间区间，检验目标在哪里

64 帧 + 真实 PTS
+ query

→

Qwen 一次调用
Direct 原生判断

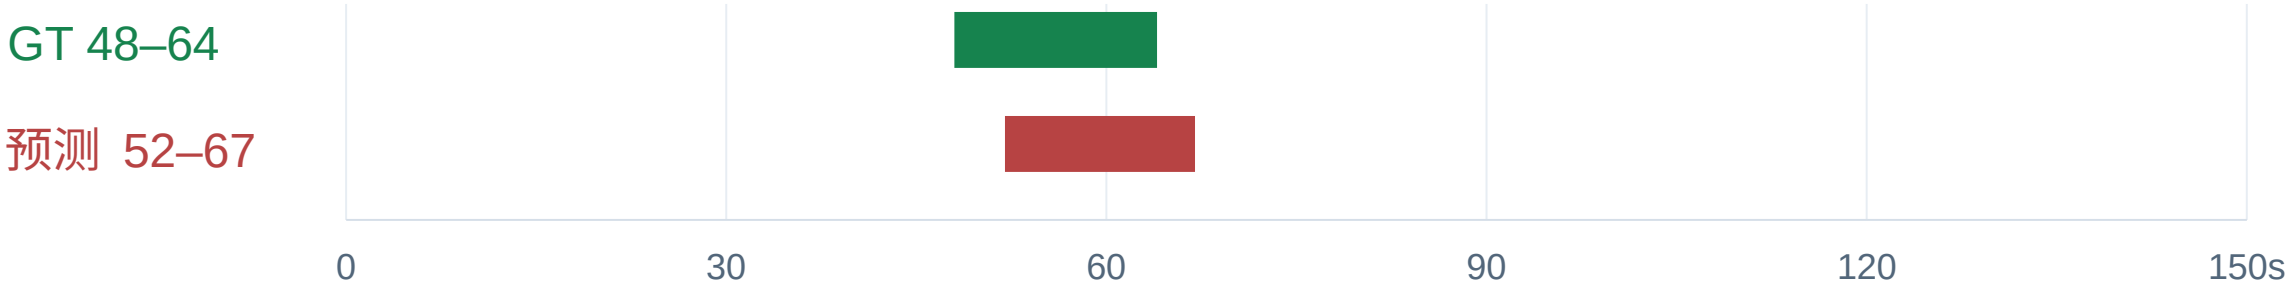
→

[start, end]
或 not_found / uncertain

本轮无候选重排、记忆或回看；评价使用定位 R1，与高光 mAP 分开。

qid 5073 ｜准备麦片

IoU = 0.6316



同一样本旧整表全 0；这里任务与输出均改变，不能作为严格单变量精度提升。
本轮使用正 query，尚未验证负 query 的拒答能力。

依据： Grounding 主线说明与首轮结果（10.29）

扩样获得 52 条反例，100 条未全部完成

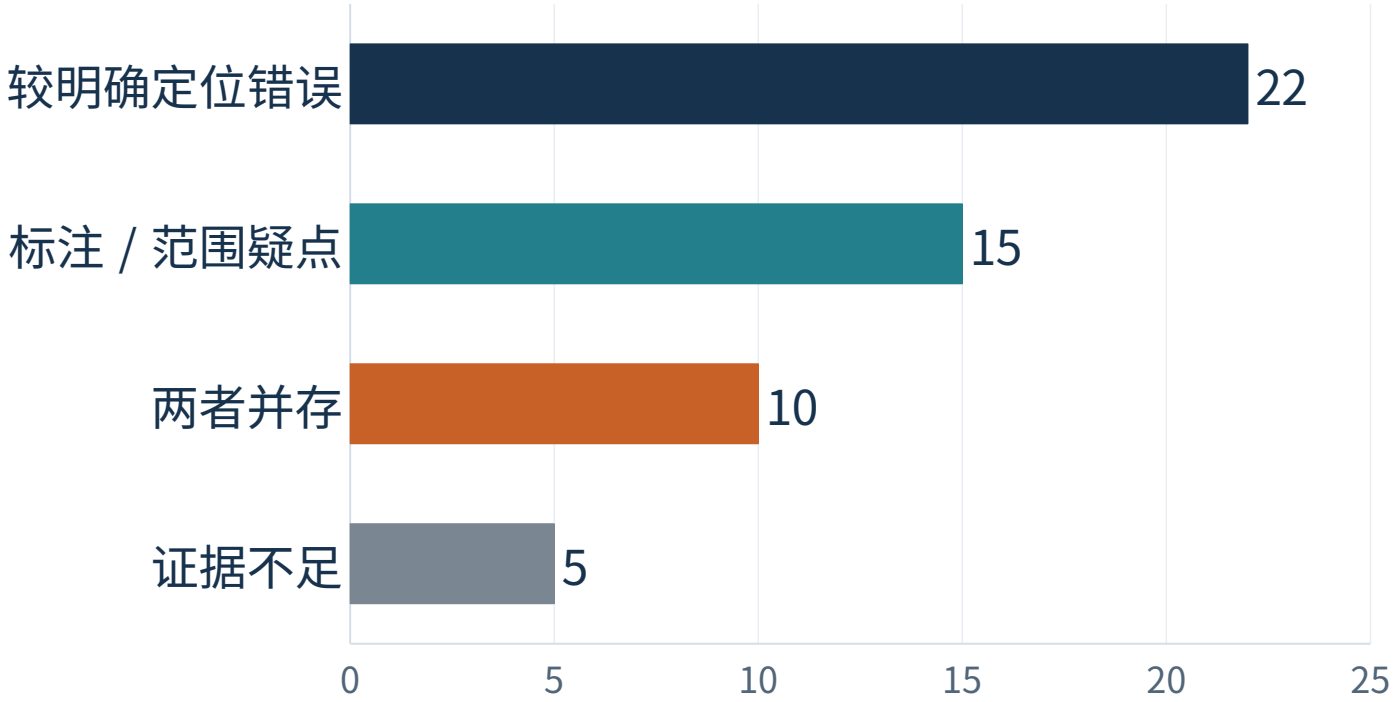
样本	执行情况	R1@0.5	R1@0.7	合法反例数
首轮 QV20	20/20 合法	70%	50%	6 条
新增 100 条	96 尝试 / 94 合法	42%	28%	52 条

100 = 94 合法 + 1 OOM + 1 非法区间 + 4 未尝试

扩样 R1 按完整 100 条计算，技术缺失计零；反例定义为合法输出且 IoU < 0.5 。
两批 query 和源视频不重叠；均为 train 开发诊断，差值不能归因于方法退化。

依据： Grounding 首轮与扩样 100 结果（10.29）；非官方全量验证

52 条指标失败，不能全部归因于模型



5 / 14

零 IoU 反例中仍有相关事件

零重叠不能自动等同于内容找错。

52/52 基于原始 64 帧的助手核查，尚无独立人工复核；分类数量不是人工标注真值。未更改发布 GT 或重算有利指标，也不能外推为整个数据集的标签错误率。

依据： 52 条反例分析与逐例审核记录（10.29）

真正定位错误：鸡舍被定位成花景

qid 448 | The chickens are in a coop.

Published GT: [[92, 112]] | Prediction: [130, 145]

Frames in published GT



Original frame #40 | PTS 94.90s



Original frame #43 | PTS 101.93s



Original frame #46 | PTS 108.97s

Frames in model prediction



Original frame #56 | PTS 132.40s



Original frame #58 | PTS 137.10s



Original frame #60 | PTS 141.77s

Post-hoc evidence display only. Original pixels and PTS; no new video frames or model calls.

qid 448 ｜查询：鸡在鸡舍里

GT　92–112 s

预测　130–145 s

IoU = 0

GT 可见围栏内的鸡；
预测主要是道路、花朵
和文字牌，事件不匹配。

待检验：对象与场景核验

本页展示失败证据，尚无修复结果。

依据： qid 448 原输入帧证据卡与反例审核； GT 为发布标注

疑似漏标：模型找到了前一次布置圣诞树

qid 3676 | A woman wearing a santa hat is setting up a small Christmas tree.
Published GT: [[118, 144]] | Prediction: [0, 24]

Frames in published GT



Original frame #51 | PTS 120.70s　Original frame #55 | PTS 130.07s　Original frame #58 | PTS 137.10s

Frames in model prediction



Original frame #02 | PTS 5.83s　Original frame #04 | PTS 10.53s　Original frame #06 | PTS 15.23s

Post-hoc evidence display only. Original pixels and PTS; no new video frames or model calls.

qid 3676 ｜布置圣诞树

GT　118–144 s

预测　0–24 s

IoU = 0

5.83 、 10.53 、 15.23 s
可见戴圣诞帽女子整理
小树，预测内容有依据。

待人工确认动作与实例范围

这是漏标疑点，尚不能确认 GT 错误。

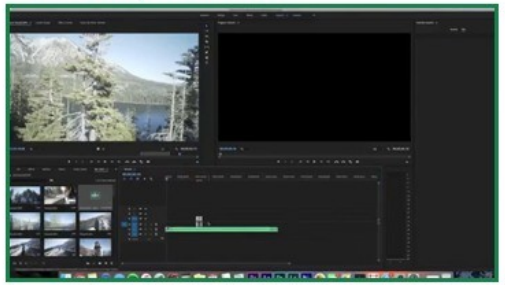
依据： qid 3676 原输入帧证据卡与反例审核；保留发布 GT

边界与标注问题可能同时存在

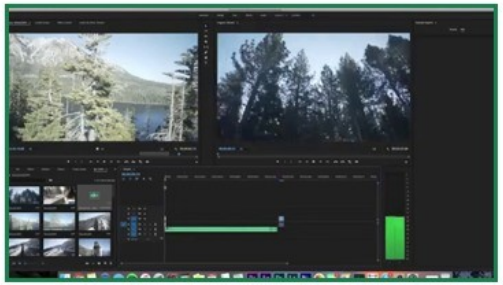
qid 5466 | Video editing software showing how the video was made.

Published GT: [[0, 8], [48, 62]] | Prediction: [38, 57]

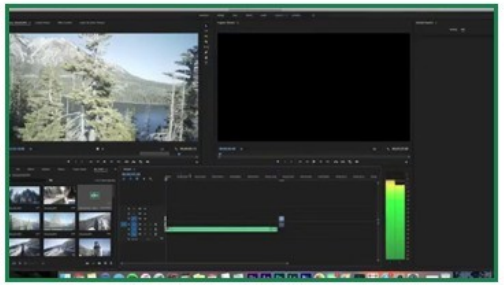
Frames in published GT



Original frame #21 | PTS 50.38s

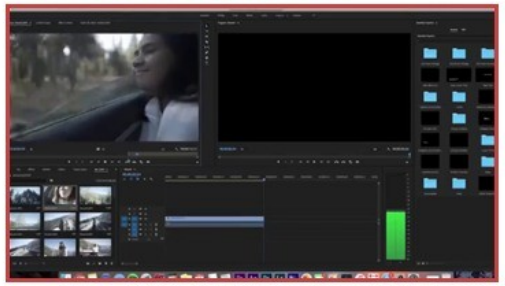


Original frame #24 | PTS 57.39s

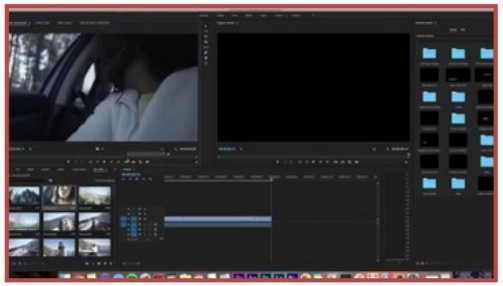


Original frame #25 | PTS 59.76s

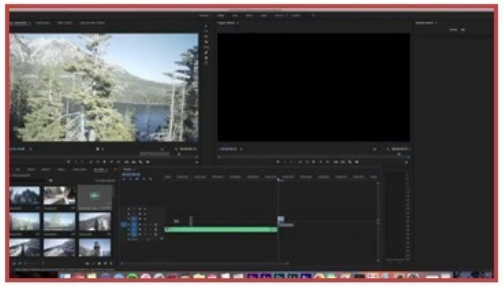
Frames in model prediction



Original frame #16 | PTS 38.64s



Original frame #17 | PTS 41.01s



Original frame #23 | PTS 55.06s

Post-hoc evidence display only. Original pixels and PTS; no new video frames or model calls.

qid 5466 ｜展示编辑软件

GT　0–8 、 48–62 s

预测　38–57 s

IoU = 0.3750

起点疑点： 38.64 s 已有软件，GT 从 48 s 开始可能偏晚。

终点错误： 约 59 s 仍有软件，预测在 57 s 结束偏早。

精确秒级边界仍需连续视频核验。

依据： qid 5466 原输入帧证据卡与反例审核

分批执行可用，定位问题仍需验证

已处理的运行保障

GPU 编号兼容、输入与源码冻结。

分批冷启动 worker；
保留账本、失败和进程退出记录。

非法区间严格拒绝，
没有静默交换端点或额外重试。

仍未解决的问题

OOM： 缓存累积仍是主要线索，
尚无独立 GPU 修复验证。

出现非法输出 [150,17]；扩样余 4 条、
TVSum Direct 余 5 条未补跑。

输入仅 64 帧、无声音；动作含义与
精确边界仍需连续视频和人工核验。

本阶段产出是可追溯的基线与反例； Agent 修复效果尚未验证。

依据： Direct 运行报告、 Grounding 扩样报告与反例分析

下一步：按错误类型验证局部补证

先用可靠反例验证补证，再扩大 Agent 实验

核验较明确错误

原帧 + 连续视频片段

选错事件

对象、动作、关系和场景
是否同时满足 query？

边界错误

检查起点之前与终点之后

标注疑点

人工复核重复实例
与 query 动作范围；
保留发布 GT。

语音相关案例单独核查。

验收：修复率 + 原命中误改 + 全分母 R1 + 调用成本